

# Конспект по Дискретной математике.

Чепелин В.А.

## Содержание

### 1 Лекция 1.

1.1 Аксиоматическое вероятное пространство. . . . .

### 2 Лекция 2.

2.1 Случайная величина. . . . .

2.2 Мат. ожидание. . . . .

2.3 Незав. случайные величины . . . . .

2.4 Дисперсия случайной величины. . . . .

### 3 Лекция 3.

3.1 Ковариация . . . . .

3.2 Корреляция . . . . .

3.3 Хвостовые неравенства . . . . .

### 4 Лекция 4.

4.1 Введение в теорию информации. . . . .

4.2 Энтропия . . . . .

### 5 Лекция 5.

5.1 Марковские цепи . . . . .

### 6 Лекция 6.

### 7 Лекция 7.

7.1 Формальные языки . . . . .

7.2 Описание языка. . . . .

7.3 Регулярные (автоматные языки) . . . . .

7.4 Детерминированный Конечный Автомат (ДКА) . . . . .

### 8 Информация о курсе

# 1 Лекция 1.

## 1.1 Аксиоматическое вероятное пространство.

Пусть у нас есть  $\Omega$  - элементарные исходы и связанная с ним функция  $p : \Omega \rightarrow [0, 1]$  - дискретная вероятностная мера (плотность вероятности) - функция, которая по элементарному исходу возвращает вероятность.

А также  $\sum_{w \in \Omega} p(w) = 1$ , а также  $0 \leq p_i \leq 1$  А также мы считаем, что  $|\Omega|$  не более чем счетно. Для множеств мощности континуума нам нужна более сложная теория.

Рассмотрим **примеры**:

1. Честная монета:

$$\Omega = \{0, 1\}. p(0) = p(1) = \frac{1}{2}.$$

2. Нечестная монета или распределение Бернулли:

$$\Omega = \{0, 1\}. p(0) = 1 - p(1) = q.$$

3. Честная игральная кость:

$$\Omega = \{1, 2, 3, 4, 5, 6\}. p(w) = \frac{1}{6}. p(w) = \frac{1}{52}$$

4. Колода карт:

$$\Omega = \{\langle c, r \rangle \mid 1 \leq c \leq 4, 1 \leq r \leq 15\}$$

5. Геометрическое распределение:

$$\Omega = \mathbb{N}, p(i) = \frac{1}{2^i}$$

**Замечание.** Не существует равномерного распределения на счетном множестве.

**Событие** — множество  $A \subset \Omega$ .  $P(A) = \sum_{w \in A} p(w)$ . (Иногда используют  $\Pr$ ).

$P(A) = 1$  — достоверное событие.

$P(A) = 0$  — невозможное событие.

Рассмотрим примеры на честной игральной кости:

1. Только четные:  $P(A) = \frac{3}{6} = \frac{1}{2}$ .

2. Больше 4-ех:  $P(A) = \frac{2}{6} = \frac{1}{3}$ .

**Замечание:** нельзя с равной вероятностью выбрать случайное целое число.

**Независимые события** — A, B независимы, если  $P(A \cap B) = P(A) \cdot P(B)$ .

$\frac{P(A \cap B)}{P(B)} = \frac{P(A)}{P(\Omega)}$  — независимы (если произошло B, то вероятность не поменялась)

$P(A|B) = \frac{P(A \cap B)}{P(B)}$  — вероятность A при условии B — условная вероятность.

Произведение вероятностных пространств.

Пусть у нас есть  $\Omega_1, p_1$ , а также  $\Omega_2, p_2$ , тогда произведение вероятностных пространств:

$$\Omega = \Omega_1 \times \Omega_2$$

$$p(\langle w_1, w_2 \rangle) = p_1(w_1) \cdot p_2(w_2)$$

**Утв.**  $\forall A \subset \Omega_1, B \subset \Omega_2$ .

$A \times \Omega_2$  и  $\Omega_1 \times B$  независимы.

Пусть у нас есть  $n$  событий:  $A_1, A_2, \dots, A_n$ .

Тогда обычно **независимость  $n$  событий** подразумевает:

1.  $A_i, A_j$  - независимы  $\forall i, j, \quad i \neq j$
2.  $\forall I \subset \{1, 2, 3, \dots, n\}: P(\bigcap_{i \in I} A_i) = \prod_{i \in I} P(A_i)$

### Формула полной вероятности

$\Omega = A_1 \cup A_2 \cup \dots \cup A_n, \forall i \neq j: A_i \cap A_j = \emptyset$  — **полная система событий**.

Возьму  $B$  - какое-то событие.

$$P(B) = \sum_{i=1}^n P(B \cap A_i) = \sum_{i=1}^n P(B|A_i) \cdot P(A_i)$$

Пример: урна с шариками. Сначала выбираете урну, потом достаете шарик.

### Формула Байеса.

$$P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} = \frac{P(B|A_i) \cdot P(A_i)}{\sum_{j=1}^n P(B|A_j) \cdot P(A_j)}$$

## 2 Лекция 2.

### 2.1 Случайная величина.

**Случайная величина** или численная характеристика каждого элементарного исхода — это отображение  $\xi : \Omega \rightarrow \mathbb{R}$ , которое сопоставляет каждому элементарному исходу какое-то число.

**Пример:**

1.  $D = \{1, 2, \dots, 6\}$ . Возьмем  $\Omega = D^2$ . Например, человек бросает два игральных кубика. Тогда, очевидно,  $p(\langle i, j \rangle) = \frac{1}{36}$ . И тогда он задает функцию случайной величины, например, как  $\xi(\langle i, j \rangle) = i + j$ .
2. Возьмем случайный граф  $G$  на  $n$  вершинах.  $\xi(G) =$  количеству компонент связности. Или  $\xi(G) =$  количеству ребер в этом графе.
3. Давайте кидать игральный кубик и сопоставим каждой выпадающей грани число, равное количеству точек на этой грани. То есть  $\Omega = \{1, 2, \dots, 6\}$ ,  $\xi(i) = i$ .
4.  $\Omega = \{1, 2, \dots, 6\}$ ;  $E = \{2, 4, 6\}$ .  $x_E(w) = \begin{cases} 1, w \in E \\ 0, w \notin E \end{cases}$

Возьмем какие-то  $\Omega, p, \xi$ :

$[\xi = i] = \{w | \xi(w) = i\} \subset \Omega$  — множество элементарных исходов, случайная величина которых равна  $i$ .

**def:**  $f_\xi : \mathbb{R} \rightarrow \mathbb{R}$  — дискретная плотность вероятности  $\xi$ .


$$P([\xi = i]) = P(\xi = i) = f_\xi(i) = \sum_{w \in [\xi=i]} p(w)$$

**Дискретная плотность вероятности** — это функция, которая говорит нам, насколько вероятно каждое из этих отдельных значений, которые может принимать случайная величина. Другими словами, она присваивает вероятность каждому возможному исходу.

Немного поменяем и получим  $[\xi \leq i] = \{w | \xi(w) \leq i\} \subset \Omega$ .

$$P([\xi \leq i]) = P(\xi \leq i) = F_\xi(i)$$

**def:**  $F_\xi : \mathbb{R} \rightarrow \mathbb{R}$  — функция распределения. У дискретной случайной величины функция распределения ступенчатая. Например:



## 2.2 Мат. ожидание.

Математическое ожидание — среднее значение случайной величины.

$$E_{\xi} = \sum_w p(w) \xi(w) = \sum_i i \cdot P(\xi = i).$$

Дальше А.С. использует 3 вида обозначений:

1.  $E_{\xi}$  2.  $E(\xi)$  3.  $E\xi$  — не боимся, это одно и то же.

Теорема (линейность мат ожидания)

$$E\lambda\xi = \lambda E_{\xi} \quad E_{(\xi+\eta)} = E_{\xi} + E_{\eta}$$

**Доказательство:**

$$E\lambda\xi = \sum_w p(w) \cdot \lambda\xi(w) = \lambda \sum_w p(w) \xi(w) = \lambda E_{\xi}$$

$$E(\xi + \eta) = \sum_w p(w)(\xi(w) + \eta(w)) = \sum_w p(w)\xi(w) + \sum_w p(w)\eta(w) = E(\xi) + E(\eta)$$

Q.E.D.

МАТ. ОЖИДАНИЕ ВСЕГДА ЛИНЕЙНО!!!

## 2.3 Незав. случайные величины

$\xi, \eta$  - независимы, если  $[\xi = a], [\eta = b]$  — независимы  $\forall a, b$ .

Эквивалентное утверждение —  $[\xi \leq a], [\eta \leq b]$  — независимы  $\forall a, b$ .

Иначе говоря, две случайные величины называются *независимыми*, если по значению одной нельзя сделать выводы о значении другой.

**Теорема (о мультипликативности мат. ожидания)**

$\xi, \eta$  — независимы  $\Rightarrow E(\xi \cdot \eta) = E_\xi \cdot E_\eta$ .

**Доказательство:**

$$\begin{aligned} E_{(\xi \cdot \eta)} &= \sum_a a P(\xi, \eta = a) = \sum_a a \sum_{\forall i, j: i \cdot j = a} P(\xi = i, \eta = j) = \\ &= \sum_a \sum_i \sum_j a P(\xi = i) P(\eta = j) = \sum_i i P(\xi = i) \cdot \sum_j j P(\eta = j) = E_\eta \cdot E_\xi \end{aligned}$$

Q.E.D.

**2.4 Дисперсия случайной величины.**

$D_\xi = Var(\xi)$  — дисперсия случайной величины.

$$D_\xi = E((\xi - E_\xi)^2) = E_{\xi^2} - (E_\xi)^2$$

**Дисперсия случайной величины** — это мера того, насколько сильно разбросаны значения этой случайной величины вокруг её математического ожидания (среднего значения). Другими словами, она показывает, насколько "широко" распределение вероятностей случайной величины.

**Теорема (свойства дисперсии).** Если  $\xi, \eta$  - независимы:

$$D_{c\xi} = c^2 D_\xi \quad D_{\xi+\eta} = D_\xi + D_\eta$$

Доказательство тривиально из линейности мат. ожидания.

## 3 Лекция 3.

### 3.1 Ковариация

$$Cov(\xi, \eta) = E_{\xi\eta} - E_{\xi}E_{\eta}$$

**Ковариация** или **корреляционный момент** показывает на сколько зависимы случайные величины это мера зависимости двух случайных величин.

Если  $\xi, \eta$  - независимые случайные величины

$$Cov(\xi, \eta) = 0$$

:

$$Cov(\xi, \xi) = D_{\xi} = Var_{\xi} - \text{вариация}$$

### 3.2 Корреляция

$$Corr(\xi, \eta) = \frac{E_{\xi\eta} - E_{\xi}E_{\eta}}{\sqrt{D_{\xi} \cdot D_{\eta}}} = \frac{Cov(\xi, \eta)}{\sqrt{D_{\xi} \cdot D_{\eta}}}$$

**Корреляция** - статистическая взаимосвязь двух случайных величин. Корреляция является **нормированной** версией ковариации, что позволяет сравнивать силу линейной зависимости между различными парами переменных, независимо от их масштаба.

**Теорема (об ограниченности корреляции)**

$$-1 \leq Cor(\xi, \eta) \leq 1$$

**Доказательство:**

Возьму  $\alpha = \xi - \lambda\eta$ :

$$D\alpha = D(\alpha) = E\xi^2 - 2\lambda E_{\xi\eta} + \lambda^2 E\eta^2 - (E\xi)^2 + 2\lambda E_{\xi}E_{\eta} - \lambda^2 (E\eta)^2 \geq 0$$

$$D\xi - 2\lambda Cov(\xi, \eta) + \lambda^2 D\eta \geq 0$$

Откуда, если рассматривать это, как уравнение относительно  $\lambda$ , то  $D \leq 0$ , то есть:

$$4Cov(\xi, \eta) - 4D_{\eta}D_{\xi} \leq 0$$

А если присмотреться, то это и есть то, что нам надо.


Q.E.D.

### 3.3 Хвостовые неравенства

Рассмотрим азартную игру. ~~не одобряем, не играем.~~

Проводится случайный эксперимент, смотрится значение  $\xi$ . Если оно получилось 100 или больше, то мы платим 100 рублей, а иначе наш друг платит нам 100 рублей. Мы знаем  $E\xi = 10, \xi \geq 0$ .

Хотим оценить  $P(\xi \leq 100)$ :



Давайте посмотрим, является ли наша вероятность меньше  $\frac{1}{2}$ . Тогда всё, что правее 100 имеет вероятность выпадения  $\geq \frac{1}{2}$ . Все левое оценивается нулем, откуда мат ожидание хотя бы 50. Такого быть не может. В общем случае:

### Теорема (Неравенство Маркова)

$$\xi \neq 0, \xi \geq 0 : \forall a \geq 1 : P(\xi \geq a \cdot E\xi) \leq \frac{1}{a}$$

**Доказательство:**

$$E\xi = \sum_v v \cdot P(\xi = v) = \sum_{v < a \cdot E\xi} v P(\xi = v) + \sum_{v \geq a \cdot E\xi} v P(\xi = v) \geq \sum_{v \geq a \cdot E\xi} a E\xi P(\xi = v) = a E\xi \cdot P(\xi \geq a \cdot E\xi)$$

Q.E.D.

### Теорема (Неравенство Чебышева)

Абсолютная версия и относительная версия ( $\alpha = \lambda\sigma$ ):

$$P(|\xi - E\xi| \geq \alpha) \leq \frac{D\xi}{\alpha^2} \quad P(|\xi - E\xi| \geq \lambda\sigma) \leq \frac{1}{\lambda^2}$$

**Доказательство:**

Возьму вот такие величины:

$$D\xi = E(\xi - E\xi)^2 \quad \eta = (\xi - E\xi)^2$$

Заметим, что  $E\eta = D\xi$ . Используем неравенство Маркова для оценки дисперсии:

$$P(\eta \geq c \cdot E\eta) \leq \frac{1}{c}$$

Возьму  $c = \frac{D\xi}{\alpha^2}$  и получу искомое.

Q.E.D.

**Нечестная монета.** Вот вам дали домашку, вместе с вопросом  $p > \frac{1}{2}$  или  $p < \frac{1}{2}$ . Что вы можете делать? Только кидать ее, но при этом бесконечное количество раз вы не кинете, у вас дедлайн домашки через час.



Пусть мы бросили  $n$  раз. Выпало  $c$  единиц и  $n - c$  нулей. Пусть  $c \leq \frac{n}{2}$ :

$$P(\xi = c) \leq P(\xi \leq c) \leq P(|\xi - pn| \geq pn - c) \leq P(|\xi - pn| \geq \frac{n}{2} - c) \leq \frac{n}{4} \cdot \frac{1}{\left(\frac{n}{2} - c\right)^2}$$

Что это концептуально значит? На самом деле, это дает нам оценку на распределение. Зачем? Чтобы **СДАТЬ** домашку.

### Теорема (Граница Чернова)

$$P(\xi \geq (1 + \varepsilon)p) \leq e^{-\frac{\varepsilon^2}{2+\varepsilon}np} \quad \Leftrightarrow \quad P(\xi \geq (1 + \varepsilon)p) \leq e^{-\frac{\varepsilon^2}{2}np}$$

$$e^{-\frac{\varepsilon^2}{3}np} \leq \delta \quad \Leftrightarrow \quad -\frac{\varepsilon^2}{3}np \leq \ln \delta$$

$$n \geq \frac{3}{p\varepsilon^2} \ln \frac{1}{\delta}$$

Не знаю, что это концептуально, напишите пж

## 4 Лекция 4.

### 4.1 Введение в теорию информации.

информация = - неопределенность - сказал дяденька Шеннон

Для осознания нам поможет рисунок АС:



Есть что-то - неизвестное - облачко. Затем, вы с помощью глаза заглядываете туда, и ваша неопределенность уменьшается. Соответственно вы получили информацию. То есть сначала была неопределенность  $H_1$ , потом  $H_2$ .  $I = H_1 - H_2$ , откуда и получается наша формула. У него есть глубокий смысл, но создается вопрос: «И че? И что это за неопределенность?»

Ну наличие глаза мешает, непонятно, фу фу фу. Поэтому хотим ввести что-то более формальное и менее абстрактное.

Пусть у нас есть какой-то случайный эксперимент  $\Omega$ , с вероятностями  $p_1, \dots, p_n$ . И вот мы получили информацию что выпало (например орел на монетке).

**Случайный источник** — черный ящик с красной кнопкой, который показывает номер эл. исхода, когда вы нажимаете на красную кнопку.

Возьмем монетку. Кинули, получили 0 или 1. Теперь возьмем кубик, получим число от 1 до 6. Когда мы кидаем кубик, мы получаем больше информации. И вот Шеннон решил систематизировать все это...

### 4.2 Энтропия

Пусть у нас есть случайный источник и вероятности  $p_1, p_2, \dots, p_n$ . Мы хотим померить численно сколько информации содержится в одном эксперименте:

$$H(p_1, \dots, p_n) : RS \rightarrow R^+$$

**Энтропия Шеннона** ( $H$ ) - это мера неопределенности или случайности, связанная с случайной переменной. Она измеряет среднее количество информации, необходимое для описания результата случайной переменной. Иными словами, энтропия показывает, насколько непредсказуемым является источник информации.

Возьму пример  $p_i = \frac{1}{n}$ . Введем новое обозначение:

$$h(n) = H\left(\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n}\right)$$

Очевидно, что  $h(n+1) > h(n)$ .

Теперь рассмотрим вероятностное пространство и источник на нем:

$$\Omega = \{(1, 1), (1, 1), \dots, (1, m_1), (2, 1), \dots, (k, 1), \dots, (k, m_k)\}$$

И давайте теперь каждому причислим какую-то  $q_{ij}$ , так, что в сумме 1.  $p_i = \sum_{j=1}^{m_i} q_{ij}$ . Пусть наш случайный источник сломан и показывает только одно число. Если я возьму сломанный случайный источник от  $\Omega$ , то мы получим столько же информации сколько и у случайного источника сделанного из  $p$ .

Теперь давайте делить это на 2 части. Что вот мы сначала видим первую часть информации, а потом хоба и видим вторую часть информации. И того мы получаем, что когда мы открываем вторую часть мы получим  $p_i H(\frac{q_{i1}}{p_i}, \dots, \frac{q_{im_i}}{p_i})$  информации. Откуда благодаря таким рассуждение получаем свойство, которое называется аддитивностью энтропии:

$$H(p_1, \dots, p_k) + \sum_{i=1}^k p_i H(\frac{q_{i1}}{p_i}, \dots, \frac{q_{im_i}}{p_i}) = H(q_{11}, \dots, q_{mk})$$

Также для фиксированного  $n$ ,  $H$  непр из  $\mathbb{R}^n \rightarrow \mathbb{R}$ .

Теорема.(Формула энтропии Шеннона)

$$H(p_1, \dots, p_n) = -\alpha \sum_{i=1}^n p_i \log_2 p_i$$

$\alpha$  отвечает за выбор единицы измерений.

**Доказательство:**

Лемма 1.  $h(n \cdot m) = h(n) + h(m)$ .

**Доказательство:**

Возьмем  $k = n, m_i = m, p = \frac{1}{n}, q_{ij} = \frac{1}{nm}$ . Из утверждения сверху это верно!

Q.E.D.

Фиксируем  $h(2) = \alpha$ . Тогда:

Лемма 2.  $h(2^k) = k\alpha$ . тривиально из Леммы 1.

Лемма 2,5.  $h(n^r) = rh(n)$ . тривиально из Леммы 1.

Лемма 3.  $h(n) = \alpha \log_2 n$

**Доказательство:**

Найду  $i$  такое, что  $2^i \leq n^r < 2^{i+1}$ , где  $r \in \mathbb{N}$ .

Из монотонности  $h$  следует:  $\alpha i \leq h(n^r) < \alpha(i+1)$ . Поэтому:

$$\alpha i \leq rh(n) < \alpha \Leftrightarrow a \frac{i}{r} \leq h(n) \leq a \frac{i+1}{r}$$

Также мы знаем, что  $i \leq r \log_2 n < i + 1$ . Получим, что:

$$\alpha \frac{i}{r} \leq \alpha \log_2 n < \alpha \frac{i+1}{r}$$

То есть  $\forall r : |h(n) - \alpha \log_2 n| \leq \frac{\alpha}{r}$ . Откуда, получаем требуемое равенство.

Q.E.D.

Возвращаемся к доказательству теоремы. Пусть  $p_i$  рациональные. Приведем все  $p$  к общему знаменателю и пусть теперь  $p_i = \frac{a_i}{b_i}$ . Возьму  $m_i = a_i$ ,  $r_{ij} = \frac{1}{a_i}$ ,  $q_{ij} = \frac{1}{n}$ . Подставим во второе неравенство получим:

$$H\left(\frac{1}{b}, \frac{1}{b}, \dots, \frac{1}{b}\right) = H(p_1, p_2, \dots, p_k) + \sum_{i=1}^k p_i H\left(\frac{1}{a_i}, \dots, \frac{1}{a_i}\right)$$

Что тут происходит? Я разбиваю каждый исход изначальный, на  $a_i$  исходов по  $\frac{1}{b_i}$ . С одной стороны я получаю  $b$  исходов по  $\frac{1}{b}$ . С другой стороны я могу выбрать исход, а потом его разбить. Откуда по аддитивности и получается такая формула. А она в свою очередь уже удобная, так как в ней повторяются значения внутри  $H$ , так что можем заменить на  $h$ :

$$h(b) = H(p_1, \dots, p_k) + \sum_{i=1}^k p_i h(a_i)$$

Заметим, что  $\sum_{i=1}^n p_i = 1$ , так что левую часть на эту сумму:

$$\sum_{i=1}^n p_i h(b) = H(p_1, \dots, p_k) + \sum_{i=1}^k p_i h(a_i)$$

$$H(p_1, \dots, p_k) = \sum_{i=1}^n p_i (h(b) - h(a_i))$$

$$H(p_1, \dots, p_k) = \sum_{i=1}^n p_i (\alpha \log_2 b - \alpha \log_2 a_i) = -\alpha \sum_{i=1}^n p_i \log_2 p_i$$

Эта формула верна и не для рац. исходя непрерывности (любое не рац. можно зажать с двух сторон сходящимися последовательностями и мы победили)

Q.E.D.

$\alpha$  — бит, единица информации.

Обычно используется логарифм по основанию 2, тогда энтропия измеряется в битах (или "Шеннонах"). Если используется натуральный логарифм (основание  $e$ ), то энтропия измеряется в натах. Использование логарифма по основанию 10 даёт единицы измерения в децитах (Hartleys). Выбор основания влияет только на масштаб энтропии, а не на её относительные значения.

Энтропия Шеннона имеет широкое применение в различных областях, включая:

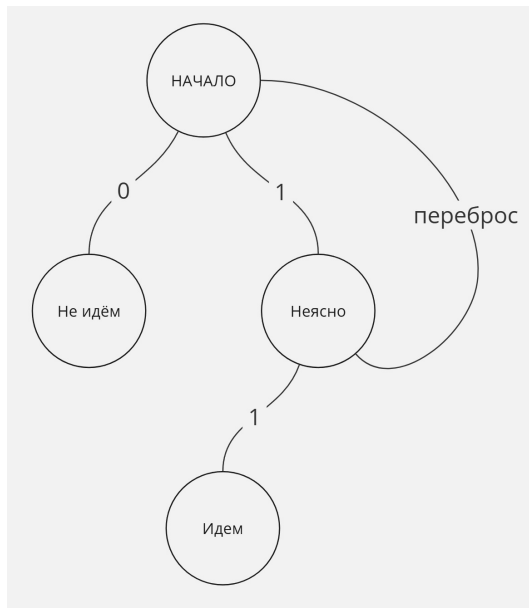
- Теория информации: Является фундаментальным понятием для измерения количества информации.
- Сжатие данных: Используется для оценки теоретического предела сжатия данных.
- Криптография: Оценка случайности ключей и стойкости шифров.
- Машинное обучение: В деревьях решений используется для выбора признаков, которые лучше всего разделяют данные.
- Обработка естественного языка (NLP): Оценка неопределенности в языковых моделях.
- Термодинамика: Аналогична термодинамической энтропии, отражает меру беспорядка в системе.

Также есть такие понятия, как взаимная энтропия и условная энтропия. Их определения появятся в конспекте после того, как пройдет неделя со сдачей домашки.

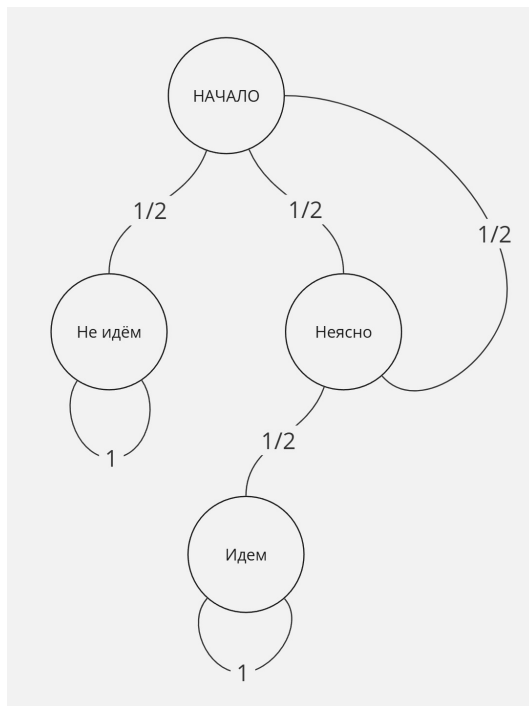
## 5 Лекция 5.

### 5.1 Марковские цепи

Вспоминаем задачку с Петей, монеткой и кинотеатром и визуализируем в виде ориентированного графа.



Заметим, что результаты нам не особо важны, важны только вероятности, перерисуем и дополнительно заведём ограничение на сумму значений вероятностей исходящих из вершины: сумма должна всегда должна быть равна единичке.



Давайте для такого графа введём определение.

**Марковской цепью** называется ориентированный граф с конечным числом вершин, у которых на исходящих рёбрах написаны вероятности, причём для каждой вершины верно, что сумма этих рёбер равна единице. Введём ещё парочку определений.

Вершина называется **поглощающей** если из неё исходит только петля.

Обозначим векторами  $b_i^{(t)} = P(\xi_t = i)$ ,  $b^t = (b_1^{(t)}, \dots, b_n^{(t)})$  - распределение  $\xi_t$ .

Давайте с такими данными построим матричку  $P_{n \times n}$ , где значение в ячейке – это вероятность перейти из  $i$ -той вершины в  $j$ -тую. Разберём пример:

$$P = \begin{pmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 1 & 0 & 0 \\ \frac{1}{2} & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Хочется что-то с этой матрицей начать делать, начнём же:

**Лемма 1.**  $b^{(t+1)} = b^{(t)} P$

**Доказательство:**

$$b_i^{(t+1)} = P(\xi_{t+1} = i) = \sum_{j=1}^n P(\xi_{t+1} = i \ \& \ \xi_t = j) P(\xi_t = j) = \sum_{j=1}^n b_j^{(t)} P_{ji} = (b^{(t)} P)_i$$

Q.E.D.

По коэффициенту очевидности  $b^{(t)} = b^{(0)} P^t$ , проверяйте сами

МЦ называется **поглощающей**, если  $\forall u \exists$  путь такой, что  $u \rightarrow$  поглощаемая вершина

Введём отношение эквивалентности такое, что  $u \sim v$  если  $\exists$  пусть  $u \rightarrow v$  и наоборот.

Можем заметить, что у нас образуется разбиение на классы эквивалентности, рассмотрим  $[1; n] / \sim$ ,  $\tilde{u}$  – класс эквивалентности

$\tilde{u}$  – **эргодический класс**. тем самым мы можем разделять задачи на две части: на наблюдение свойств в самом классе и между классами.

МЦ – **эргодическая**, если в ней ровно 1 эргодический класс

Эргодический класс называется **периодическим**, если  $\exists d > 1$ , что размер любого цикла делится на  $d$  – сама  $d$  называется **периодом**, очевидно, что период – нод длин всех циклов

**Теорема о классификации Марковских Цепей.**

В любой МЦ есть поглощающий эргодический класс, вероятность того, что МЦ окажется в одном таких классов стремится к единице

Вторая часть, я не могу разобрать свой почерк, на паре мы это не доказывали пока

**Доказательство:**

$$P = \left( \begin{array}{c|c} Q & R \\ \hline \mathbf{0} & E \end{array} \right), \text{ где } Q_{m \times m}, R_{m \times (n-m)}, \text{ где } m - \text{это непоглощающие эргодические классы}$$

тогда каждый вектор  $b^{(t)}$  делится на две части: первые  $m$  координат обозовём  $a^{(t)}$ , вторые назовём  $c^{(t)}$ .  $a_i^{(t)} = P(\xi_t = i)$ , где  $i$  непоглощающая

**Лемма 2.**  $a^{(t)} = a^{(0)}Q^t$ , лемма очевидна просто взгляните, на то, как умножается вектор на матрицу

**Лемма 3.**  $Q^k \xrightarrow{k \rightarrow +\infty} 0$

**Доказательство:**

Для того, чтобы найти предел матрицы нам нужно ввести норму, норму введём такую  $|A| = \max_{ij} |a_{ij}|$ , сами докажете, что это норма, не маленькие.

Тогда матрица стремится к нулю, если её норма стремится к нулю, наша задача показать, что  $Q^n \xrightarrow{n \rightarrow +\infty} 0$

Пусть  $L$  - максимальная длина кратчайшего пути от  $i$  до поглощения, давайте посмотрим чему равно  $X = Q^L$ , рассмотрим  $x_{ij} = \sum_{k_1, k_2, \dots, k_{l-1}} q_{ik_1} q_{k_1, k_2} q_{k_2, k_3} \dots q_{k_{l-1}, j}$ . Чему равна эта сумма, неясно, каждое из этих произведений – это вероятность пройти оп пути длиной ровно  $L$  от вершины  $i$  до  $j$ , давайте рассмотрим такую сумму

$$\sum_{j\text{-не погл}} x_{ij} = \sum_{k_1, k_2, \dots, k_{l-1}, j} q_{ik_1} q_{k_1, k_2} q_{k_2, k_3} \dots q_{k_{l-1}, j} = \delta < 1$$

Меньше единицы оно потому, что мы смотрим не на все пути, а лишь на часть. Посмотрим на матричку:

$$Q^n_{ij} = (Q^L Q^{n-L})_{ij} = \sum_k Q^L_{ik} Q^{n-L}_{kj} \leq (\sum_k Q^L_{ik}) |Q^{n-L}| \leq \delta |Q^{n-L}| \text{ т.к. } |Q^n| \leq \delta^{[n/L]}$$

то наше выражение стремится к нулю

Лемму доказали, стало быть, и теоремка доказана.

Передём к вычислительным моментам, мы хотим понять, где мы поглотимся. Найдём мат. ожидание времени до поглощения. Давайте введём  $T$  – случайная величина : число шагов до поглощения, тогда  $T = \sum_{i=1}^m T_i$  – число посещений  $i$ -го состояния

$$T_i = \sum_{j=0}^{\infty} T_{ij}$$

$$T_{ij} = \begin{cases} 1, & \text{если на шаге } j \text{ марковская цепь находится в состоянии } i, \\ 0, & \text{иначе.} \end{cases}$$

$$P(\text{м.ц на шаге } j \text{ в состоянии } i) = (a^0 Q^j)_i$$

$$ET = \sum_{i=1}^n ET_i = \sum_{i=1}^m \sum_{j=0}^{\infty} ET_{ij} = \sum_{i=1}^m \sum_{j=0}^{\infty} (a^0 Q^j)_i$$



Воспользуемся линейной алгеброй, т.к. сумма матриц перестановочна относительно взятия  $i$ -го компонента

$$\sum_{i=1}^m \sum_{j=0}^{\infty} (a^0 Q^j)_i = \sum_{i=1}^m \left( \sum_{j=0}^{\infty} a^0 Q^j \right)_i$$

т.к.  $a^0$  не зависит от  $j$

$$\sum_{i=1}^m \left( \sum_{j=0}^{\infty} a^0 Q^j \right)_i = \sum_{i=1}^m a^0 \left( \sum_{j=0}^{\infty} Q^j \right)_i$$

Q.E.D.

**Лемма**  $\sum_{j=0}^{\infty} Q^j = (I - Q)^{-1}$

**Доказательство:**

$$\begin{aligned} (E - Q)(E + Q + Q^2 + Q^3 + \dots) &= E - Q + Q - Q^2 + Q^2 + \dots - Q^{n+1} \\ &= E - Q^{n+1} = E \text{ т.к. } Q \text{ стремится к нулю} \end{aligned}$$

Q.E.D.

**Фундаментальная матрица поглощения м.ц.** – это  $N = (I - Q)^{-1}$

$$\begin{aligned} P(\text{погл в } j) &= \sum_i^m P(\text{погл в } j \text{ из } i) P(j \text{ перед поглощением}) = \sum_t^{\infty} \sum_{i=1}^m P(\text{погл в } j \text{ из } i \text{ в } t) \\ &= P(\text{быть в } i \text{ в момент времени } t) = a^0 N R \end{aligned}$$

Откуда получаем 2 крутые и очень полезные в дальнейшем формулы:

## 6 Лекция 6.

Поглощающий эргодический класс – класс, из которог в конденсации нет рёбер

МЦ регулярная если  $\forall i, j \ P_{i,j} > 0$

Теорема: Эргодическая теорема для марковских цепей

$$\exists b \ \forall b^{(0)} P^{(n)} \xrightarrow{n \rightarrow \infty} b \text{ и } bP = b$$

**Доказательство:**

Давайте возьмём наш вектор  $b^{(0)}$  и умножим на матрицу  $A$  такую, что  $A \in M_{n \times n}$  и  $\forall j \ a_{ji} = \tilde{a}$

$$(b \cdot A)_i = \sum_{j=1}^n b_j a_{ji} = (\sum_{j=1}^n b^{(0)}_j) \tilde{a}_i = \tilde{a}_i. \text{ т.к. сумма в столбике } b^{(0)} \text{ всегда равна единичке}$$

Докажем, что  $P^n \xrightarrow{n \rightarrow \infty} A$ , удовлетворяющей условиям.

Введем  $M_i^{(t)} = \max(P^t)_{ji}$ ,  $m_i^{(t)} = \min(P^t)_{ji}$ , посмотрим на разность максимума и минимума в столбце, правда ли он стремится к нулю?

Возьмём  $\delta = \max P_{ij}$  и  $\tilde{\delta} = \min P_{ij}$

$$\begin{aligned} (P^{(t+1)})_{ij} &= (P \cdot P^t)_{ij} = \sum_{k=1}^n P_{jk} (P^t)_{ki} \leq \sum_{k \neq \text{pos}(\min)} P_{jk} \cdot M_i^{(t)} + P_{j, \text{pos}(\min)} m_i^{(t)} = \\ &= \sum_{k=1}^n P_{ik} \cdot M_i^{(t)} + P_{j, \text{pos}(\min)} (m_i^{(t)} - M_i^{(t)}) \leq M_i^{(t)} - \delta A_i^{(t)} \end{aligned}$$

с другой стороны

$$(P^{(t+1)})_{ij} = (P \cdot P^t)_{ij} = \sum_{k=1}^n P_{jk} (P^t)_{ki} \geq \sum_{k=1}^n P_{jk} m_i^{(t)} + P_{j, \text{pos}(\max)} (M_i^{(t)} - m_i^{(t)}) = m_i^{(t)} + \tilde{\delta} A_i^{(t)}$$

$$\begin{aligned} M_i^{(t+1)} &\leq M_i^{(t)} - \delta A_i^{(t)} \\ m_i^{(t+1)} &\geq m_i^{(t)} + \tilde{\delta} A_i^{(t)} \end{aligned}$$

минусуем

$$A_i^{(t+1)} \leq A_i^{(t)} - (\delta - \tilde{\delta} A_i^{(t)}) = (1 - \delta - \tilde{\delta}) A_i^{(t)} \leq \dots \leq (1 - \delta - \tilde{\delta})^{(t+1)} \rightarrow 0$$

Если разность стремится к 0, то в  $b^{(0)} P^{(n)} \xrightarrow{n \rightarrow \infty} b^0 A = b$

Q.E.D.

Давайте научимся искать  $b$ , решим следующее уравнение:  $(I - P)b = \mathbf{0}$ . Казалось бы, это СЛОУ и она может иметь либо 0 решений, либо бесконечно много, тогда почему же у нас есть конкретное решение? На самом деле,  $(I - P)$  – вырожденная, и она имеет ранг  $n - 1$  и у нас одномерное пространство решений, но нам подойдёт только тот вектор, у которого сумма координат единичка. Тогда как в итоге найти  $b$ ?

У нас есть два способа, мы либо возведём много раз матрицу  $P$  в квадрат, с какого-то момента это всё будет стремиться к  $A$ , мы найдём ответ и, тогда сможем вычислить  $b$ , все операции займут у нас  $O(n^3c)$ , понятно, что если использовать какие-то продвинутые алгоритмы, оценку можно улучшить.

Либо же просто решим систему уравнений, но это тоже имеет свои тонкости, как минимум нам понадобится работать с вещественными числами, а мы знаем, что вещественные числа в компьютере несовершенны и дорого с ними работать, хоть и асимптотика номинально  $O(n^3)$ , но она упирается в проблемы работы с даблами.

Наши теоремы мы доказали только для регулярных МЦ, но что происходит с нерегулярными?

### Теорема

Если  $P$  – матрица нерегулярного эргодического класса, тогда  $\exists t : P^t$  - регулярное Доказывать мы это не будем, просто поверим на слово

## 7 Лекция 7.

### 7.1 Формальные языки

Алфавит -  $\Sigma$  - конечное или пустое

Множество слов длины  $n$ :  $\Sigma^n$

$$\Sigma^* = \bigcup_{k=0}^{\infty} \Sigma^k$$

Язык - подмножество слов в алфавите  $L \subset \Sigma^*$

Замечание. Множество языков  $2^{\Sigma^*}$  несчетно.

### 7.2 Описание языка.

Вот мы хотим описать язык. И описать его словами например: все слова четной длины, они содержат четное число единиц. Но мы не можем дать эти слова компьютеру или человеку, говорящему на другом языке.

Поэтому существует несколько способов описания языков:

1. Перечисление: Явное перечисление всех слов в языке (возможно только для конечных языков). Например,  $L = \{a, ab, aba\}$ .
2. Порождающая грамматика (формальная грамматика): Набор правил, определяющих, какие слова принадлежат языку.
3. Распознающий автомат: Машина (например, конечный автомат), которая принимает или отклоняет слова в зависимости от того, принадлежат они языку или нет.
4. Регулярное выражение: Шаблон, описывающий структуру слов в языке.
5. Предикат: Математическое условие, которому должны удовлетворять слова, чтобы принадлежать языку.

Замечание. Всего описаний счетное множество

**Фанфакт.** Если вы захотите найти лексикографически минимальный язык без описания, то когда вы найдете его, у него появится описание. Мы не будем думать об этом и такого рода парадоксах

### 7.3 Регулярные (автоматные языки)

У нас есть операция конкатенации, определена она таким образом:

$$\alpha, \beta \in \Sigma^* : \varphi = \alpha\beta, \text{ причем } \alpha \in \Sigma^K, \beta \in \Sigma^l, \alpha\beta \in \Sigma^{k+l}, \text{ а также } \varphi_i = \begin{cases} i \leq k \Rightarrow \alpha_i \\ i > k \Rightarrow \beta_{i-k} \end{cases}$$

Она ассоциативна и есть нейтральный элемент  $\varepsilon$ .

Но теперь хотим ввести понятие конкатенации языков:

$$AB = \{x | x = yz, y \in A, z \in B\}$$

**Пример:**

$A = \{0, 01\}, B = \{0, 10\}$ , тогда  $AB = \{00, 010, 0110\}$

А теперь обо всех операциях

Пусть  $L_1$  и  $L_2$  - языки над алфавитом  $\Sigma$ . Тогда можно определить следующие базовые операции:

1. Объединение:  $L_1 \cup L_2 = \{w | w \in L_1 \vee w \in L_2\}$
2. Конкатенация:  $L_1 L_2 = \{w_1 w_2 | w_1 \in L_1, w_2 \in L_2\}$
3. Степень:  $L_1^0 = \{\varepsilon\}, L_1^{n+1} = L_1 L_1^n$
4. Замыкание Клини:  $A^* = \bigcup_{k=0}^{\infty} A^k$

$Reg_0 = \{\emptyset, \{\varepsilon\}, \{c\} \text{ for } c \text{ in } \Sigma\}$  - базовые регулярные языки

$Reg_{i+1} = Reg_i \cup \{A \cup B, AB, A^* | A, B \in Reg_i\}$

Семейство регулярных языков  $Reg = \bigcup_{k=0}^{\infty} Reg_k$

Лемма:

$A, B \in Reg \Rightarrow A \cup B \in Reg, AB \in Reg, A^* \in Reg.$

Доказательство:

$A \in Reg_i, B \in Reg_j$ , откуда по определению  $A \cup B, AB, A^* \in Reg_{\max(i,j)+1}$

Q.E.D.

$X \in Good, X \subset 2^{\Sigma^*}, X - \text{set}(\text{language}), Good - \text{set}(\text{set}(\text{language}))$

Good - множество множеств языков. Мы называем его хорошим если:

1.  $Reg_0 \subset X$
2.  $X$  замкнут относительно базовых операций.

Теорема.  $Reg = \bigcap_{u \in Good} u$

Доказательство не будет.

$\emptyset$  - пустое множество,  $\varepsilon$  - пустая строка.

Пусть у языка  $A$  описание  $\alpha$ . У языка  $B$  описание  $\beta$ . Тогда введем обозначение:

1.  $AB$  описание будет  $\alpha\beta$  — средний приоритет
2.  $A \cup B$  описание будет  $\alpha|\beta$  — минимальный приоритет
3.  $A^*$  описание будет  $a^*$  — максимальный приоритет

В зависимости от приоритета будем заключать выражения в скобки. Такие записи называются академическими регулярными выражениями.

Также есть еще две обозначения:

1.  $\alpha^+ = \alpha\alpha^*$ .
2.  $\alpha^k = \alpha \dots \alpha$  -  $k$  раз.

## 7.4 Детерминированный Конечный Автомат (ДКА)

В разделе марковских цепей у нас были графы с вероятностями на ребрах. А давайте теперь удалим вероятности.

$A = \langle \Sigma, Q, S, T, \sigma : Q \times \Sigma \rightarrow Q \rangle$ , где

1.  $\Sigma$  - алфавит
2.  $Q$  - конечное множество состояний
3.  $S \in Q$  - начальное состояние.
4.  $T \subset Q$  - допускающее (конечное) состояние.
5.  $\sigma$  - функция перехода, которая по текущему состоянию переходит

$Snap = Q \times \Sigma^*$  — множество мгновенных описаний автомата или состояний.

$\vdash: \langle a, \alpha \rangle \vdash \langle r, \beta \rangle$

1.  $\alpha = c\beta, c \in \Sigma$
2.  $r = \delta(q, c)$

Это описание того, как мы бегаем по графу. То есть например пусть у нас есть автомат, который описывает четное или нечетное число единиц в строке и ему подали 0101. Тогда для него мгновенные описания:

$$\langle ch, 0101 \rangle \vdash \langle ch, 101 \rangle \vdash \langle nech, 01 \rangle \vdash \langle nech, 1 \rangle \vdash \langle ch, \varepsilon \rangle$$

Языком автомата  $L(A) = \{w | \langle s, w \rangle \vdash^* \langle t, \varepsilon \rangle, t \in T\}$

### Теорема (Клини)

$Reg = Aut$ , где  $Aut$  - множество языков, задающихся ДНК.

Доказательства не будет

## 8 Информация о курсе

Поток — у2024.

Группы М3138-М3142.

Преподаватель — Станкевич Андрей Сергеевич.

В данном семестре фокусируются 2 темы: Дискретная теория вероятности и представление слов (токенов) в компьютере.

